

Derin öğrenme ile kolon hastalıklarının tespiti

İlkay Özkan
İstanbul Topkapı Üniversitesi
Bilgisayar Mühendisliği
ilkayozkan@stu.topkapi.edu.tr

Ahmet Koç
İstanbul Topkapı Üniversitesi
Bilgisayar Mühendisliği
ahmetkoc1@stu.topkapi.edu.tr

Özetçe— Kolon hastalıklarının tespiti, erken müdahale ve hasta sağkalımı için oldukça önemlidir. Bu çalışmada, kolon hastalıklarının sınıflandırılmasına yönelik, derin öğrenme tabanlı bir model geliştirilmiştir. Model, 4000 kolon görüntüsü üzerinde eğitilerek dört farklı hastalık sınıfını tanımlamayı amaçlamaktadır. EfficientNetB5 modeli, transfer öğrenme ile kolon görüntüleri için yeniden eğitilmiş ve veri çoğaltma teknikleriyle modelin genelleme kabiliyeti artırılmıştır. Model, test setinde yüksek doğruluk oranı ile başarılı sonuçlar elde etmiş olup, derin öğrenme tekniklerinin tıbbi tanı alanındaki uygulamalarına katkı sunmaktadır.

Anahtar Kelimeler—Kolon hastalıkları, kolorektal kanser, görüntü işleme, tıbbi görüntüleme, konvolüsyonel sinir ağıları (CNN), derin öğrenme, hastalık tespiti, bilgisayarlı tanı sistemleri

I. GİRİŞ

Derin öğrenme modelini oluşturmadan önce hastalıkların yapısını ve özelliklerini anlamak, başarılı bir özellik çıkarımı için kritik öneme sahiptir. Hastalıkların karakteristik özelliklerini tanımak, modelin doğruluğunu artırmak için temel oluşturur ve CNN gibi modellerin doğru sınıflandırma yapmasına katkı sağlar.

A. Ülseratif Kolit



Şekil 1a Ülseratif Kolit

Kalın bağırsağın iç yüzeyinde kronik iltihaplanma ve yaralar (ülserler) oluşturan inflamatuvar bir bağırsak hastalığıdır. Bu hastalık, karın ağrısı, ishal, rektal kanama gibi semptomlarla kendini gösterir ve hastaların yaşam kalitesini ciddi şekilde etkileyebilir. Ülseratif kolit, başlangıçta hafif semptomlarla ortaya çıkabilir, ancak ilerleyen dönemlerde komplikasyon riski yüksektir. Erken ve doğru teşhis, hastalığın yönetiminde kritik rol oynar. Tanı sürecinde, endoskopik görüntüleme ve biyopsi gibi yöntemler kullanılsa da bu işlemler zaman alıcı ve yorucu olabilir (Şekil 1a gösterilmiştir).

B. Polip



Şekil 1b Polip

Polip, vücudun iç yüzeylerinde anormal hücre büyümesi sonucu oluşan genellikle iyi huylu tümör veya çıkıntılardır. Çoğunlukla bağırsak, rahim, burun gibi organlarda görülür. Bağırsaklarda oluşan polipler ileride kansere dönüşme riski taşıyabilir, bu yüzden düzenli kontrollerle izlenmeleri ve gerekli durumlarda alınmaları önemlidir. (Şekil 1b de gösterilmiştir)

C. Özafajit



Şekil 1c Özafajit

Özofajit, yemek borusunun veya ince bağırsağın (özofagus) iltihaplanması anlamına gelir. Bu iltihap genellikle asit reflüsü, enfeksiyonlar veya bazı ilaçların kullanımı nedeniyle oluşur. Özofajit, göğüs ağrısı, yutma güçlüğü, yemek yedikten sonra yanma gibi belirtilerle kendini gösterir. Tedavi edilmeyen özofajit yemek borusunda yaralanmalara neden olabilir. (Şekil 1c de gösterilmiştir).

II. METODLAR

A. Gerekli Kütüphanelerin İmport Edilmesi

TensorFlow, Keras ve diğer destekleyici kütüphaneler projeye dahil edilmiştir. Bu kütüphaneler modelin oluşturulması, eğitim ve görselleştirme gibi işlemlerde kullanılmıştır.)

B. Veri Setinin Yüklenmesi ve Ayarlanması


Eğitim ve test verileri, belirtilen dizinlerden yüklenmiştir. Her resmin boyutu standart hale getirilmiş ve her birinde 64'lük paketler şeklinde yükleme yapılmıştır. Veriler, etiketlenmiş kategorik biçimde yüklenmiş ve karıştırılmıştır

C. Veri Ön İşleme

Görüntü boyutlandırma ve ölçeklendirme işlemleri yapılmıştır. Resimler 224x224 boyutuna getirilmiş ve 1/255 ile çarpılarak normalize edilmiştir.

D. Veri Çoğaltma, Görselleştirme

Eğitim verileri üzerinde çeşitli veri artırma (data augmentation) işlemleri uygulanmıştır. Bu işlem, modelin daha genelleştirilmiş ve sağlam hale gelmesine yardımcı olmuştur. Yatay çevirme, rastgele döndürme, yakınlaştırma ve kontrast ayarlama gibi çeşitli görüntü dönüştürmeleri yapılmıştır. Bu dönüştürmelerin sonucunda elde edilen örnekler görselleştirilerek incelenmiştir.



Şekil 2a Çoğaltılmış veri örneği

E. Modelin oluşturulması (Transfer Learning)

EfficientNetB5 modeli, transfer öğrenme ile önceden eğitilmiş bir model olarak kullanılmıştır. Bu model, ağırlıkları ImageNet veri kümesinden aldığı için hızlı bir başlangıç sağlamakta ve modelin doğruluğunu artırmaktadır. EfficientNetB5 modelinin çıktıları alınıp, bu katmana ekstra sınıflandırma katmanları eklenmiştir. EfficientNetB5'in çıktısına kendi oluşturduğumuz katmanlar eklenmiştir. İlk olarak global ortalama havuzlama


(GlobalAveragePooling2D) katmanı eklenmiş, ardından 256 nöronlu tam bağlantılı (Dense) bir katman eklenmiştir. Bu katmana, aşırı öğrenmeyi azaltmak amacıyla bir bırakma (Dropout) katmanı eklenmiştir. Son katmanda ise 4 sınıfa göre tahmin yapması için softmax aktivasyon fonksiyonuna sahip bir sınıflandırma katmanı bulunmaktadır.

F. Modelin Derlenmesi ve Eğitimi

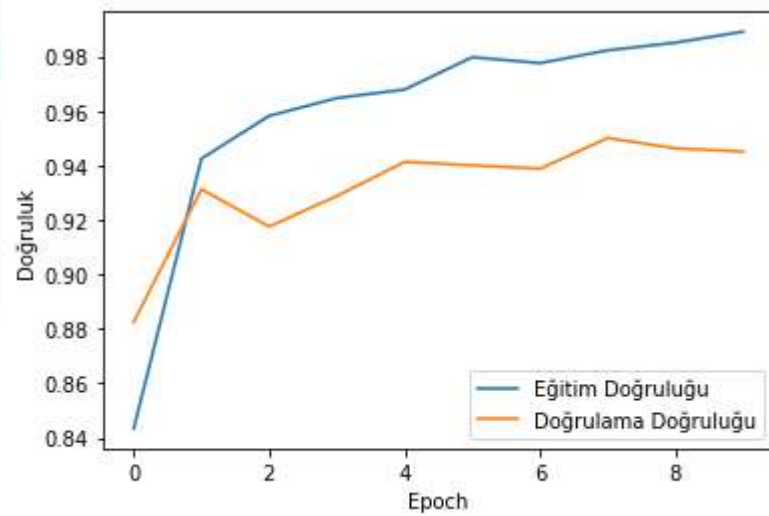
Model, adam optimizasyon algoritması ve kategorik çapraz entropi kaybı ile derlenmiştir. Eğitim işlemi, eğitim ve doğrulama verileri üzerinde toplamda 10 dönem (epoch) boyunca gerçekleştirilmiştir. Ayrıca, en iyi modeli kaydetmek için bir kontrol noktası (Checkpoint) ve erken durdurma (EarlyStopping) işlevleri kullanılmıştır.

III. SONUÇLAR

Eğitim aşamalarının tamamlanmasından sonra modelimiz eğitilmiş testleri yapılmış hale geliyor ve bu bölümde veri görselleştirme ile sonuçları değerlendireceğiz.




Şekil 3a Modelin kayıp oranları



Şekil 3b Modelin doğruluk oranları

Modelin eğitim sürecindeki doğruluk ve kayıp oranlarının değişimi gösterilmektedir. **Eğitim ve Doğrulama Doğruluğu Grafiği** modelin her bir epoch boyunca eğitim ve doğrulama setleri üzerindeki doğruluk oranlarını karşılaştırır. Eğitim doğruluğu eğrisi, modelin eğitim verisi üzerinde öğrendiği bilgiyi nasıl genelleştirdiğini gösterirken, doğrulama doğruluğu eğrisi modelin yeni verilere nasıl yanıt verdiğini değerlendirmektedir. Eğer her iki eğri de artış gösteriyor ve aralarındaki fark büyük değilse model veriyi iyi öğrenmekte ve genelleme yapabilmektedir. **Eğitim ve Doğrulama Kayıp Grafiği** ise modelin her bir epoch'ta hata oranını gösterir. Eğitim kaybı eğrisi modelin eğitim setindeki hatalarını yansıtırken, doğrulama kaybı eğrisi modelin doğrulama setinde yaptığı hataları gösterir. Eğitim kaybı ve doğrulama kaybı benzer seviyelerde azalıyorsa model, fazla öğrenmeye başlamadan veriyi iyi öğrenmiş demektir. **Şekil (3a) ve Şekil(3b).**

Ardından, test görüntülerinden rastgele 64 görüntü seçilerek, her bir görüntü modelin tahmin ettiği sınıf ve gerçek sınıf etiketi ile birlikte 8x8'lik bir grid düzeninde görselleştirilmiştir. Görüntülerin başlıkları, tahmin edilen sınıf ile gerçek sınıfın uyumuna göre renklendirilmiştir: Modelin doğru tahmin ettiği görüntülerin başlığı yeşil, yanlış tahmin edilenlerin başlığı ise kırmızı renkte gösterilmiştir. Bu sayede, modelin sınıflandırma doğruluğu görsel olarak incelenmiş ve yanlış sınıflandırılan görüntüler belirgin hale getirilmiştir. **Şekil (3c)**



Şekil 3c Tahmin tablosu

REFERENCES

- [1] <https://www.kaggle.com/datasets/francismon/curated-colon-dataset-for-deep-learning>(Kasım2024):23:04
- [2] https://keras.io/examples/vision/image_classification_from_scratch/
(Kasım2024):23:04
- [3] <https://www.tensorflow.org/tutorials/keras/classification?hl=tr>
(Kasım2024):23:04



Ahmet KOÇ

İstanbul Topkapı Üniversitesi Bilgisayar Mühendisliği

Java ile nesne tabanlı programlama, veri analizi ve mühendislik uygulamaları için Matlab, otomasyon ve yapay zeka çözümleri için Python



İlkey Özkan

İstanbul Topkapı Üniversitesi Bilgisayar Mühendisliği

Kotlin ile Android uygulamaları geliştirme. Java ile nesne tabanlı programlama ve Swing kütüphanesi kullanarak masaüstü uygulamalar, otomasyon ve yapay zeka çözümleri için Python